

부하테스트 결과 정리

starttoo · 2026-08-08 · 발표 Q&A 대비용

동시 접속 100명까지 실패 없이 처리했고, 병목은 서버가 아니라 이미지 전송 대역폭으로 특정했습니다.

측정 방법

항목	내용
도구	k6 (Grafana)
실행 위치	로컬 PC → 실제 배포 도메인 (HTTPS · nginx 포함한 실제 경로)
시나리오	피드 조회 → 게시물 상세 → 이미지 다운로드 → 검색 → 아티스트 목록
사용자 행동	각 동작 사이 1~5초 대기 (실제 사용자처럼)
부하 패턴	30초 증가 → 2분 유지 → 30초 감소 (회차당 3분)
범위	읽기 전용 (운영 데이터 보호를 위해 쓰기 제외)

핵심 수치

모든 구간에서 **실패 0건**. 아래 값은 p95 — 100명 중 95명이 이 시간 안에 응답받았다는 뜻이며, 평균보다 체감을 잘 반영합니다.

동시 사용자	피드	상세	검색	이미지	처리량	실패
5명	373ms	194ms	212ms	723ms	2.0/s	0
30명	409ms	243ms	294ms	892ms	11.6/s	0
50명	1.89s	1.07s	1.25s	5.64s	16.5/s	0
100명	3.97s	2.03s	2.25s	8.18s	25.8/s	0
100명 (이미지 제외)	339ms	194ms	275ms	—	31.5/s	0

부하 최고점의 서버 자원 사용률

nginx	backend	postgres	minio	redis	backend 메모리
0.23%	0.55%	0.00%	0.07%	0.54%	794MB / 15.6GB

결론

- API 처리 능력은 동시 100명도 여유 — 이미지를 제외하면 100명에서도 p95 339ms
- 병목은 이미지 전송 하나 — 이미지를 뺀 100명(339ms)이 이미지를 포함한 30명(409ms)보다 빠름
- 서버 자원은 무관 — 응답이 4초일 때도 전 컨테이너 CPU 1% 미만
- 한계를 넘겨도 장애가 아니라 지연 — 약 5,000건 요청에서 에러·타임아웃 0건

측정된 대역폭 상한은 약 1.4 MB/s(11 Mbps)로, 부하를 건 PC 회선이 먼저 막힌 것으로 보입니다. 서버 처리 성능에 대한 결론은 이미지를 제외한 측정으로 분리 검증했습니다.

예상 질문 & 답변

Q. 몇 명까지 버티나요?

API 기준으로는 100명까지 p95 339ms로 여유가 있었습니다. 이미지를 포함한 실사용 기준으로는 30명까지가 쾌적한 구간이고(p95 0.4초), 50명부터 이미지 전송이 지연되기 시작합니다.

Q. 병목이 뭔가요?

이미지 전송입니다. 부하 최고점에서도 서버 CPU가 1% 미만이었는데 응답은 4초씩 걸렸습니다. 이미지 요청만 제외하고 같은 100명 부하를 다시 걸었더니 응답시간이 12배 개선되었습니다. 서버 처리가 아니라 대역폭이 원인이라는 걸 실험으로 분리해서 확인했습니다.

Q. 어떻게 개선할 건가요?

현재는 업로드된 원본 이미지를 그대로 내려주고 있습니다. 피드용 썸네일을 생성하면 전송량을 5~10배 줄일 수 있고, WebP 변환과 CDN을 추가하면 더 줄일 수 있습니다.

Q. 한계를 넘으면 서비스가 죽나요?

아닙니다. 100명 구간에서 4,965건 요청이 전부 성공했습니다. 에러나 타임아웃 없이 응답이 느려지기만 했습니다.

Q. 레이트 리미트가 있다면, 그걸 고고 측정한 건 아닌가요?

서버 처리 능력을 재는 게 목적이라 한도 면제 계정으로 측정했습니다. 다만 부하 수준 자체는 정상 범위입니다 — 사용자 1인당 분당 약 24건을 보냈는데 실제 한도는 60건이라 40% 수준입니다. 즉 실제 사용자도 이 정도로는 한도에 걸리지 않습니다.

Q. 측정 PC의 인터넷 속도가 병목이었을 수도 있지 않나요?

이미지 구간은 그럴 가능성이 있습니다. 그래서 이미지를 제외한 테스트를 따로 돌려서 API 성능을 분리해 측정했고, 그 결과는 회선 영향을 거의 받지 않습니다. 이미지 대역폭이 병목이라는 결론 자체는 어느 쪽이든 동일합니다.

Q. 쓰기(게시물 작성) 부하는 왜 안 했나요?

운영 DB에 테스트 데이터가 대량으로 쌓이는 걸 피하기 위해 읽기 전용으로 한정했습니다. 쓰기 경로는 별도 통합테스트에서 업로드부터 게시물 생성·삭제까지 전 과정을 검증했습니다.

Q. AI 도안 생성도 부하테스트했나요?

하지 않았습니다. AI 추론은 슬롯이 전역 1개라 동시성이 구조적으로 1입니다. 동시 요청 시 순차 처리되는 것은 별도로 확인했습니다.

Q. 서버 사양은요?

메모리 15.6GB이고 부하 최고점에서 백엔드가 794MB(5%)를 썼습니다. CPU도 1% 미만이라 자원은 충분한 상태였습니다.

한 번에 말하는 버전 (30초)

k6로 동시 접속 100명까지 3분씩 부하를 걸었고, 총 5,900여 건 요청에서 실패는 0건이었습니다. 다만 100명 구간에서 응답이 4초까지 느려졌는데, 서버 CPU는 1% 미만이었습니다. 그래서 이미지 요청만 제외하고 같은 부하를 다시 걸어봤더니 p95가 339ms로 12배 개선되었습니다. 병목이 서버 처리가 아니라 이미지 전송 대역폭이라는 걸 확인한 거고, 현재 원본 이미지를 그대로 내려주고 있어서 썸네일 생성으로 5~10배 개선이 가능합니다.